第二章

感知机

袁春 清华大学深圳研究生院 李航 华为诺亚方舟实验室

目录

- 1. 感知机模型
- 2. 感知机学习策略
- 3. 感知机学习算法

一、感知机

感知机(Perceptron)

- ≥>输入为实例的特征向量,输出为实例的类别,取+1和-1;
- ≫感知机对应于输入空间中将实例划分为正负两类的分离 超平面,属于判别模型;
- ∞导入基于误分类的损失函数;
- >>利用梯度下降法对损失函数进行极小化;
- ≫感知机学习算法具有简单而易于实现的优点,分为原始 形式和对偶形式;
- №1957年由Rosenblatt提出,是神经网络与支持向量机的基础。

感知机模型

- ∞定义(感知机):
- ∞假设输入空间(特征空间)是*CR"输出空间是>={+1,-1}
- № 输入x = x 表示实例的特征向量,对应于输入空间(特征空间)的点,输出 x = x 表示实例的类别,由输入空间到输出空间的函数:

$$f(x) = \operatorname{sign}(w \cdot x + b)$$

- ∞称为感知机,
- ≥>模型参数: w x, 内积, 权值向量, 偏置,
- ∞符号函数:

$$\operatorname{sign}(x) = \begin{cases} +1, & x \ge 0 \\ -1, & x < 0 \end{cases}$$

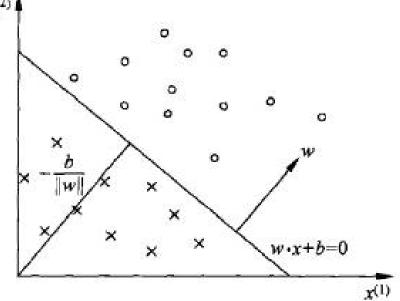
感知机模型

- ∞感知机几何解释:
- ∞线性方程:

$$w \cdot x + b = 0$$

∞对应于超平面S, w为法向量, b截距, 分离正、负类:

∞分离超平面: ※



二、感知机学习策略

感知机学习策略

- ∞如何定义损失函数?
- ≥ 自然选择:误分类点的数目,但损失函数不是w,b 连续可导,不宜优化。
- ∞另一选择: 误分类点到超平面的总距离:

$$\frac{1}{\|\mathbf{w}\|} |\mathbf{w} \cdot \mathbf{x}_0 + b|$$

误分类点距离:
$$-\frac{1}{|w|}y_i(w \cdot x_i + b)$$

总距离:
$$-\frac{1}{\|\mathbf{w}\|} \sum_{\mathbf{x} \in M} y_i(\mathbf{w} \cdot \mathbf{x}_i + \mathbf{b})$$

感知机学习策略

∞损失函数:

$$L(w,b) = -\sum_{x_i \in M} y_i(w \cdot x_i + b)$$

∞M为误分类点的数目

三、感知机学习算法

- ∞概念
- ∞相关学术资源
- >>>应用
- ∞发展历程
- ∞国内外研究者
- ∞与数据挖掘的关系
- ∞相关学术期刊和会议
- ∞与统计学习的关系

∞求解最优化问题:

$$\min_{w,b} L(w,b) = -\sum_{x_i \in M} y_i(w \cdot x_i + b)$$

- ∞随机梯度下降法,
- ≥> 首先任意选择一个超平面,w,b,然后不断极小化目标函数,损失函数L的梯度:

≫选取误分
$$\nabla_{w}L(w,b) = -\sum_{x_i \in M} y_i x_i$$
 $\nabla_{b}L(w,b) = -\sum_{x_i \in M} y_i$

$$w \leftarrow w + \eta y_i x_i \quad b \leftarrow b + \eta y_i$$

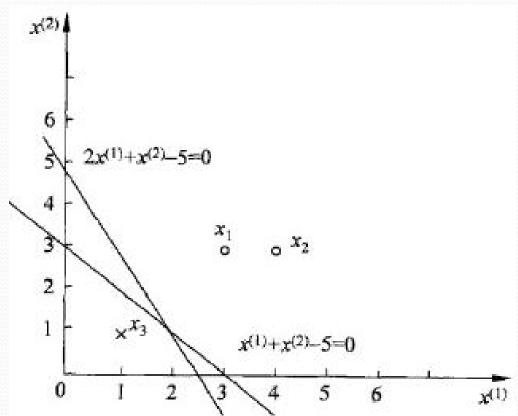
∞感知机学习算法的原始形式:

输入: 训练数据集
$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$
,
其中 $x_i \in \mathcal{X} = \mathbb{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}$, $i = 1, 2, \dots, N$
学习率 $\eta(0 < \eta \le 1)$;

输出: w,b; 感知机模型 $f(x) = sign(w \cdot x + b)$

- (1) 选取初值 w₀,b₀
- (2) 在训练集中选取数据(x_i, y_i)
- (3) 如果 $y_i(w \cdot x_i + b) \leq 0$ $w \leftarrow w + \eta y_i x_i$ $b \leftarrow b + \eta y_i$
- (4) 转至(2), 直至训练集中没有误分类点

必例: 正例: $x_1 = (3,3)^T$, $x_2 = (4,3)^T$ $x_3 = (1,1)^T$



∞解: 构建优化问题:

$$\min_{w,b} L(w,b) = -\sum_{x \in M} y_i(w \cdot x + b)$$

- ∞求解: w, b, η=1
 - (1) 取初值 $w_0 = 0$, $b_0 = 0$
 - (2) 对 $x_1 = (3,3)^T$, $y_1(w_0 \cdot x_1 + b_0) = 0$, 未能被正确分类,更新w, b $w_1 = w_0 + y_1 x_1 = (3,3)^T$, $b_1 = b_0 + y_1 = 1$
- ∞得线性模型: m·x+h=3x⁽¹⁾+3x⁽²⁾+1
- ∞ (3) x_2 , 显然, $y_i(w_i \cdot x_i + b_i) > 0$, 被正确分类,

≫得到线性模型: w₂·x+b₂ = 2x⁽¹⁾ + 2x⁽²⁾

∞如此继续下去: $w_7 = (1,1)^T$, $b_7 = -3$

$$w_7 \cdot x + b_7 = x^{(1)} + x^{(2)} - 3$$

∞分离超平面: $x^{(1)} + x^{(2)} - 3 = 0$

≫感知机模型: f(x) = sign(x⁽¹⁾ + x⁽²⁾ - 3)

迭代次数	误分类点	w	ь	$w \cdot x + b$
0		0	0	0
1	$\boldsymbol{x}_{\!\scriptscriptstyle 1}$	$(3,3)^{T}$	1	$3x^{(1)} + 3x^{(2)} + 1$
2	x ₃	$(2,2)^{T}$	0	$2x^{(1)} + 2x^{(2)}$
3	<i>x</i> ₃	(1,1) ^T	-1	$x^{(1)} + x^{(2)} - 1$
4	x_3	$(0,0)^{T}$	-2	-2
5	x ₂	$(3,3)^{T}$	-1	$3x^{(1)} + 3x^{(2)} - 1$
6	x ₃	$(2,2)^{T}$	-2	$2x^{(1)} + 2x^{(2)} - 2$
7	x_3	(1,1) ^T	-3	$x^{(1)} + x^{(2)} - 3$
8	0	$(1,1)^{T}$	3	$x^{(1)} + x^{(2)} - 3$

- ≥>算法的收敛性:证明经过有限次迭代可以得到一个将 训练数据集完全正确划分的分离超平面及感知机模型。
- ※将b并入权重向量w,记作:û=(w^T,b)^T
 x̂=(x^T,1)^T x̂∈ R^{T+1},û∈ R^{T+1} û·x̂=w·x+b
 ※定理:
- 设训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ 是线性可分的,其中 $x_i \in \mathcal{X} = \mathbb{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}$, $i = 1, 2, \dots, N$,

则

(1) 存在满足条件 $\|\hat{w}_{opt}\| = 1$ 的超平面 $\hat{w}_{opt} \cdot \hat{x} = w_{opt} \cdot x + b_{opt} = 0$: 且存在 $\gamma > 0$, 对所有 $i = 1, 2, \dots, N$ $y_i(\hat{w}_{opt} \cdot \hat{x}_i) = y_i(w_{opt} \cdot x_i + b_{opt}) \ge \gamma$

- ≫证明: (1)
- ≫由线性可分,存在超平面: $\hat{w}_{op} \cdot \hat{x} = w_{op} \cdot x + b_{op} = 0$

$$y_i(\hat{w}_{opt} \cdot \hat{x}_i) = y_i(w_{opt} \cdot x_i + b_{opt}) > 0$$

≫存在
$$\gamma = \min_{i} \{ y_i(w_{opt} \cdot x_i + b_{opt}) \}$$

©使:
$$y_i(\hat{w}_{opt} \cdot \hat{x}_i) = y_i(w_{opt} \cdot x_i + b_{opt}) \ge \gamma$$

≫证明: 令 是第k个误分类实例之前的扩充权值向量, 即:

∞第k个误分类实例的条件是:

$$y_i(\hat{w}_{k-1} \cdot \hat{x}_i) = y_i(w_{k-1} \cdot x_i + b_{k-1}) \le 0$$

 ∞ 则 \mathbf{w} 和 \mathbf{b} 的更新: $\mathbf{w}_k \leftarrow \mathbf{w}_{k-1} + \mathbf{\eta} \mathbf{y}_i \mathbf{x}_i$ $\hat{\mathbf{w}}_k = \hat{\mathbf{w}}_{k-1} + \mathbf{\eta} \mathbf{y}_i \hat{\mathbf{x}}_i$ $b_k \leftarrow b_{k-1} + \mathbf{\eta} \mathbf{y}_i$

 $\mathbb{R}^{(2)} \stackrel{\wedge}{\triangleright} \mathbb{R}^{||\mathbf{x}||}$ 感知机算法在训练集的误分类次数 \mathbf{k} 满足不等式, $\mathbb{R}^{||\mathbf{x}||}$

∞推导两个不等式:

$$\hat{w}_k \cdot \hat{w}_{\text{opt}} \ge k\eta\gamma$$

$$\hat{w}_k \cdot \hat{w}_{\text{opt}} = \hat{w}_{k-1} \cdot \hat{w}_{\text{opt}} + \eta y_i \hat{w}_{\text{opt}} \cdot \hat{x}_i$$

$$\geq \hat{w}_{k-1} \cdot \hat{w}_{\text{opt}} + \eta \gamma$$

₩得:

$$\hat{w}_k \cdot \hat{w}_{\mathrm{opt}} \geq \hat{w}_{k-1} \cdot \hat{w}_{\mathrm{opt}} + \eta \gamma \geq \hat{w}_{k-2} \cdot \hat{w}_{\mathrm{opt}} + 2\eta \gamma \geq \cdots \geq k\eta \gamma$$

 $\mathbb{R}^{(2)} \stackrel{\wedge}{=} \mathbb{R}^{|\mathbb{R}^{n}|} \mathbb{R}^{|\mathbb{R}^{n}|} \mathbb{R}$ 感知机算法在训练集的误分类次数 \mathbb{R}^{n} 满足不等式, $\mathbb{R}^{|\mathbb{R}^{n}|}$

: 则。

$$\|\hat{w}_k\|^2 \leq k\eta^2 R^2$$

$$\|\hat{w}_{k}\|^{2} = \|\hat{w}_{k-1}\|^{2} + 2\eta y_{i} \hat{w}_{k-1} \cdot \hat{x}_{i} + \eta^{2} \|\hat{x}_{i}\|^{2}$$

$$\leq \|\hat{w}_{k-1}\|^{2} + \eta^{2} \|\hat{x}_{i}\|^{2}$$

$$\leq \|\hat{w}_{k-1}\|^{2} + \eta^{2} R^{2}$$

$$\leq \|\hat{w}_{k-1}\|^{2} + 2\eta^{2} R^{2} \leq \cdots$$

$$\leq k\eta^{2} R^{2}$$

(2) 令 $R = \max_{k \in \mathbb{Z}} \| \hat{x} \|$ 。 感知机算法在训练集的误分类次数k 满足不等式, $k \leq \left(\frac{R}{2}\right)$

结合两个不等式:

$$k\eta\gamma\leqslant \hat{w}_k\cdot\hat{w}_{\text{opt}}\leqslant \|\hat{w}_k\|\|\hat{w}_{\text{opt}}\|\leqslant \sqrt{k\eta}R$$
$$k^2\gamma^2\leqslant kR^2$$

得:

$$k \leq \left(\frac{R}{\gamma}\right)^2$$

- ∞定理表明:
- ≫误分类的次数k是有上界的,当训练数据集线性可分时,感知机学习算法原始形式迭代是收敛的。
- ◎ 感知机算法存在许多解,既依赖于初值,也依赖迭代过程中误分类点的选择顺序。
- ∞为得到唯一分离超平面,需要增加约束,如SVM。
- ≥>线性不可分数据集, 迭代震荡。

- ≥>感知机算法的对偶形式:
- ≫回顾 SVM 对偶形式:
- ∞基本想法:
- ≫将w和b表示为实例xi和标记yi的线性组会的形式,通过求解其系数而求得w和b,对误分类点:

$$w \leftarrow w + \eta y_i x_i$$

 $b \leftarrow b + \eta y_i$
最后学习到的 w, b
 $w = \sum_{i=1}^{N} \alpha_i y_i x_i$
 $b = \sum_{i=1}^{N} \alpha_i y_i$

∞感知机学习算法的对偶形式:

输入: 训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 $x_i \in \mathcal{X} = \mathbb{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}$, $i = 1, 2, \dots, N$ 学习率 $\eta(0 < \eta \leq 1)$;

输出:
$$\alpha, b$$
: 感知机模型 $f(x) = \text{sign}\left(\sum_{j=1}^{N} \alpha_j y_j x_j \cdot x + b\right)$. 其中 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$

- $\infty(1) \alpha \leftarrow 0, b \leftarrow 0$
 - (2) 在训练集中选取数据(x_i,y_i)

(3) 如果
$$y_i \left(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b \right) \le 0$$

$$\alpha_i \leftarrow \alpha_i + \eta$$
$$b \leftarrow b + \eta y_i$$

(4) 转至(2)直到没有误分类数据.

Gram 矩阵 $G = [x_i \cdot x_j]_{N \times N}$

≫例: 正样本点是 $x_1 = (3,3)^T$, $x_2 = (4,3)^T$, 负样本点是 $x_3 = (1,1)^T$

解 按照算法 2.2,

(1)
$$\mathbb{R} \alpha_i = 0$$
, $i = 1, 2, 3$, $b = 0$, $\eta = 1$

(2) 计算 Gram 矩阵

$$G = \begin{bmatrix} 18 & 21 & 6 \\ 21 & 25 & 7 \\ 6 & 7 & 2 \end{bmatrix}$$

(3) 误分条件

$$y_{t}\left(\sum_{j=1}^{N}\alpha_{j}y_{j}x_{j}\cdot x_{i}+b\right) \leq 0$$

参数更新

$$\alpha_i \leftarrow \alpha_i + 1$$
, $b \leftarrow b + y_i$

 ∞ 例: 正样本点是 $x_1 = (3,3)^T$, $x_2 = (4,3)^T$, 负样本点是 $x_3 = (1,1)^T$

(4) 迭代. 过程从略, 结果列于表 2.2.

k	0	1	2	3	4	5	6	7
		<i>x</i> ₁	x ₃	<i>x</i> ₃	x ₃	\boldsymbol{x}_1	<i>x</i> ₃	<i>X</i> ₃
α_{i}	0	1	1	1	2	2	2	2
α_2	0	0	0	0	0	0	0	0
α_3	O	0	1	2	2	3	4	5
ь	0	1	0	-1	0	-1	-2	-3

(5)
$$w = 2x_1 + 0x_2 - 5x_3 = (1,1)^T$$

 $b = -3$ 分离超平面 $x^{(1)} + x^{(2)} - 3 = 0$

感知机模型 $f(x) = sign(x^{(1)} + x^{(2)} - 3)$